

Analisis Komparatif Multiproduk Presipitasi Satelit (GSMaP & GPM IMERG), Reanalisis ECMWF ERA5, dan Sensor AWS IoT Jerukagung: Evaluasi Multimetrik serta Karakteristik Iklim 20 Tahun

Evan Alif Widhyatma^{*1}

¹Program Studi Sains Data, Universitas Putra Bangsa

16 Agustus 2026

Ringkasan

Laporan teknis dan saintifik ini menyajikan evaluasi hidrometeorologi komprehensif perbandingan data curah hujan dan variabel meteorologi permukaan antara produk satelit presipitasi (*JAXA GSMaP Gauge-Calibrated*, *NASA GPM IMERG Final Run V07*), reanalisis *ECMWF ERA5 Single Levels*, serta stasiun pengamatan otomatis *AWS IoT Jerukagung*, Kabupaten Kebumen. Analisis dilakukan pada dua domain waktu: (1) evaluasi sinkron resolusi per jam (*1-hour interval*) periode 1 Januari 2025 hingga 31 Mei 2026 ($N = 12.384$ jam data valid) dan (2) rekonstruksi variabilitas iklim jangka panjang 21 tahun (2005–2025 / 252 bulan). Evaluasi mencakup diagram pencar (*scatter plot matrix & hexbin*), matriks korelasi linier Pearson (r) dan rank non-parametrik Spearman (ρ), evaluasi multimetrik error (*Mean Bias Error* / MBE, *Root Mean Square Error* / RMSE, *Mean Absolute Error* / MAE), diagram kotak (*boxplot*) sebaran residual galat, simulasi ambang batas deteksi hujan (0,2 mm/jam), uji signifikansi statistik *Wilcoxon Signed-Rank* dan *Mann-Whitney U*, analisis korelasi 13 fitur fisik atmosferik ERA5 untuk *Deep Learning Pre-Training*, serta analisis anomali klimatologi monsun. Hasil evaluasi membuktikan bahwa NASA GPM IMERG menghasilkan korelasi linier tertinggi terhadap AWS IoT ($r = 0,410$), JAXA GSMaP memiliki dispersi galat absolut dan kuadratik terendah (MAE = 0,5252 mm/jam, RMSE = 1,4997 mm/jam, MBE = -0,0168 mm/jam), sedangkan ERA5 sangat unggul dalam merekonstruksi dinamika suhu, tekanan, dan kelembapan permukaan.

Keywords: Korelasi Pearson, Korelasi Spearman, Mean Bias Error (MBE), Mean Absolute Error (MAE), Root Mean Square Error (RMSE), JAXA GSMaP, NASA GPM IMERG, ECMWF ERA5, AWS IoT Jerukagung, Wilcoxon Signed-Rank, Pre-Training Deep Learning.

1. Pendahuluan & Metodologi Penyelarasan Data

Pengukuran presipitasi dan dinamika atmosfer pada skala lokal memerlukan integrasi antara instrumen darat (*in-situ*) dengan penginderaan jauh satelit dan model reanalisis numerik. Wilayah Kebumen, Jawa Tengah, memiliki dinamika hidrometeorologis tropis yang dipengaruhi oleh sirkulasi monsun Asia-Australia serta interaksi orografis pesisir selatan Jawa.

*Email korespondensi: evanalifwidhyatma@gmail.com

1.1 Karakteristik Dataset

Empat sumber data utama yang diintegrasikan dalam penelitian ini disajikan pada Tabel 1:

1. **JAXA GSMaP (Global Satellite Mapping of Precipitation):** Produk presipitasi berbasis gelombang mikro pasif (PMW) dan inframerah (IR) terkalibrasi penakar hujan darat (*Gauge-Calibrated*).
2. **NASA GPM IMERG (Integrated Multi-satellitE Retrievals for GPM):** Produk presipitasi *Final Run V07* resolusi awal 30-menit yang diakumulasikan ke interval 1 jam.
3. **ECMWF ERA5 Reanalysis:** Dataset reanalisis iklim global generasi kelima dengan 13 parameter fisis atmosferik permukaan dan kolom total.
4. **AWS IoT Jerukagung:** Stasiun cuaca otomatis berbasis IoT lokal di Jerukagung, Kli-rong, Kebumen (koordinat $7^{\circ}40'S, 109^{\circ}39'E$) dengan sensor *tipping bucket rain gauge*, suhu, kelembapan, tekanan, dan titik embun.

Tabel 1: Spesifikasi Sumber Data Meteorologi dan Presipitasi

Sumber Data	Tipe Instrumen	Resolusi Asli	Agregasi Analisis	Variabel U
JAXA GSMaP	Satelit PMW/IR (Gauge-Cal)	1 Jam ($0,1^{\circ}$)	Akumulasi 1 Jam	Curah Hujan
NASA GPM IMERG	Satelit Multi-Sensor (Final)	30 Menit ($0,1^{\circ}$)	Akumulasi 1 Jam	Curah Hujan
ECMWF ERA5	Reanalisis Numerik Asimilasi	1 Jam ($0,25^{\circ}$)	Nilai Sesaat/Akumulasi	13 Fitur Atn
AWS IoT Lokal	Stasiun Otomatis (<i>In-situ</i>)	Interval Pengiriman IoT	Akumulasi/Rerata 1 Jam	5 Variabel C

1.2 Standarisasi Waktu dan Resampling

Seluruh stempel waktu dikonversi secara mutlak ke basis *Coordinated Universal Time* (UTC). Untuk variabel presipitasi, agregasi dilakukan dengan metode jumlahan (*sum*), sedangkan untuk variabel kontinu termodinamika (suhu, kelembapan, tekanan, titik embun) digunakan metode perataan (*mean*). Periode evaluasi sinkron mencakup rentang 1 Januari 2025 pukul 00:00 UTC hingga 31 Mei 2026 pukul 23:00 UTC, menghasilkan tepat 12.384 baris observasi berpasangan tanpa adanya data duplikat.


2. Evaluasi Variabel Meteorologi Permukaan (ERA5 vs AWS IoT)

Sebelum mengevaluasi presipitasi, dilakukan validasi terhadap variabel termodinamika permukaan antara reanalisis ERA5 dan sensor AWS IoT Jerukagung.


Gambar 1 dan 2 menunjukkan bahwa ERA5 memiliki kesesuaian yang sangat tinggi dengan stasiun AWS IoT Jerukagung untuk suhu udara ($r > 0,85$) dan tekanan permukaan ($r > 0,90$). Pola variasi harian (*diurnal cycle*) suhu dan kelembapan tertangkap secara konsisten, membuktikan keandalan ERA5 sebagai prediktor termodinamika makro.

3. Analisis Korelasi Presipitasi Jam-Jaman


Karakteristik sebaran curah hujan jam-jaman dievaluasi secara serentak menggunakan matriks diagram pencar (*Scatter Plot Matrix*) 4×4 yang disajikan pada Gambar 3.




Gambar 1: Diagram Pencar (*Scatter Plot*) Perbandingan Variabel Cuaca Permukaan: Sensor AWS IoT Jerukagung vs ECMWF ERA5 (Garis merah putus-putus menunjukkan *1:1 Perfect Fit*).



Gambar 2: Profil Rata-Rata Deret Waktu Bulanan Variabel Cuaca Permukaan (2025–2026).



Gambar 3: Matriks Diagram Pencar (*Scatter Plot Matrix*) Curah Hujan Jam-jaman Antar Seluruh Pasangan Sumber Data (Diagonal menunjukkan histogram distribusi frekuensi kejadian hujan).




Gambar 4: Diagram Pencar Detail (*Hexbin Density Plot*) Presipitasi Setiap Produk terhadap Pengamatan Stasiun AWS IoT Jerukagung (Skala logaritmik densitas titik, garis merah = regresi linier OLS, garis hitam = 1:1 *Perfect Fit*).

3.1 Matriks Heatmap Korelasi Pearson & Spearman

Hubungan linier langsung dan hubungan monotonik berbasis peringkat dihitung menggunakan formulasi Pearson (r) dan Spearman (ρ):

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}, \quad \rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (1)$$



Gambar 5: Matriks Heatmap Korelasi Curah Hujan Jam-jaman ($N = 12.384$ jam): (a) Hubungan Linier Pearson dan (b) Hubungan Monotonik Rank Spearman.

Gambar 5 dan 6 memperlihatkan bahwa:

- **NASA GPM IMERG** mencapai korelasi linier tertinggi terhadap AWS IoT Lokal ($r = 0,410$), setara dengan korelasi antar satelit GSMaP vs IMERG ($r = 0,410$).
- **JAXA GSMaP** memiliki hubungan rank monotonik yang kuat terhadap AWS IoT ($\rho = 0,341$), sedikit lebih tinggi dibandingkan IMERG vs AWS ($\rho = 0,338$).
- **ECMWF ERA5** memiliki korelasi linier yang rendah terhadap presipitasi instan AWS ($r = 0,099$), namun memiliki korelasi rank yang cukup baik ($\rho = 0,194$ vs AWS, $\rho = 0,357$ vs IMERG), mencerminkan sifat reanalisis yang menangkap waktu kejadian hujan secara makro tetapi mengalami efek penghalusan (*spatial smoothing*) pada intensitas puncak konvektif lokal.


4. Evaluasi Multimetrik Error Presipitasi vs AWS IoT Lokal

Untuk mengukur akurasi absolut dan penalti error kuadratik terhadap observasi lapangan, dihitung metrik *Mean Bias Error* (MBE), *Mean Absolute Error* (MAE), dan *Root Mean Square Error* (RMSE):

$$MBE = \frac{1}{n} \sum_{i=1}^n (S_i - O_i), \quad MAE = \frac{1}{n} \sum_{i=1}^n |S_i - O_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (S_i - O_i)^2} \quad (2)$$

di mana S_i adalah estimasi satelit/reanalisis dan O_i adalah pengamatan aktual stasiun AWS IoT.


Berdasarkan Tabel 2 dan Gambar 7–8:




Gambar 6: Diagram Batang Kekuatan Korelasi Pearson (r) Antar Seluruh Pasangan Data Presipitasi.

Tabel 2: Ringkasan Resmi Metrik Evaluasi Error Presipitasi Jam-jaman terhadap AWS IoT Jerukagung ($N = 12.384$ Jam)

Produk Presipitasi	MBE (mm/jam)	MAE (mm/jam)	RMSE (mm/jam)	Pearson r	Spearman ρ
JAXA GSMaP	-0,0168	0,5252	1,4997	0,3083	0,3408
NASA GPM IMERG	+0,5134	0,8804	2,8260	0,4105	0,3377
ECMWF ERA5	+0,0074	0,6285	1,8788	0,0992	0,1944



Gambar 7: Evaluasi Grafik Batang Metrik Galat Presipitasi terhadap AWS IoT Lokal: (a) Mean Absolute Error, (b) Root Mean Square Error, dan (c) Mean Bias Error.



Gambar 8: Diagram Kotak (*Boxplot*) Distribusi Residual Galat Presipitasi (*Satelit – AWS*) pada Kejadian Hujan Basah ($> 0,1$ mm/jam).

- **JAXA GSMaP** terbukti sebagai produk dengan galat dispersi terendah di Kebumen (MAE = 0,5252 mm/jam, RMSE = 1,4997 mm/jam) dengan bias sistematis sangat kecil (MBE = -0,0168 mm/jam).
- **NASA GPM IMERG** mengalami kecenderungan overestimasi sistematis (MBE = +0,5134 mm/jam) yang meningkatkan nilai MAE (0,8804 mm/jam) dan RMSE (2,8260 mm/jam), meskipun memiliki korelasi linier ($r = 0,4105$) tertinggi.
- **ECMWF ERA5** memiliki nilai bias mendekati nol (MBE = +0,0074 mm/jam) dengan galat absolut moderat (MAE = 0,6285 mm/jam).

4.1 Distribusi Ambang Batas Kejadian Hujan


Evaluasi diskrit terhadap kemampuan deteksi kejadian hujan dengan ambang batas (*rain threshold*) $\geq 0,2$ mm/jam disajikan pada Gambar 9. Sensor AWS IoT mencatat 2.280 jam hujan (18,4%), sedangkan GSMaP mencatat 4.581 jam (37,0%), ERA5 mencatat 3.568 jam (28,8%), dan IMERG mencatat 3.029 jam (24,5%). Hal ini mengindikasikan bahwa satelit cenderung mendeteksi presipitasi ringan di atmosfer atas yang sebagian mengalami evaporasi sebelum mencapai permukaan tanah (*virga*).

5. Uji Signifikansi Statistik Distribusi Presipitasi

Untuk menguji apakah perbedaan antar produk presipitasi signifikan secara statistik, dilakukan dua uji hipotesis non-parametrik:

5.1 Uji Wilcoxon Signed-Rank (Data Berpasangan Jam Basah)

Uji Wilcoxon diterapkan pada jam-jam di mana setidaknya salah satu produk mendeteksi hujan $> 0,1$ mm/jam (Tabel 3). Seluruh pasangan menghasilkan nilai $p < 0,001$, yang membuktikan bahwa perbedaan median magnitudo presipitasi jam-jaman antar satelit, reanalisis, dan AWS IoT berbeda nyata secara statistik.



Gambar 9: Perbandingan Jumlah Jam Kejadian Hujan ($\geq 0,2$ mm/jam) dan Tidak Hujan ($< 0,2$ mm/jam) Selama Periode Observasi.

Tabel 3: Hasil Uji Wilcoxon Signed-Rank Presipitasi Jam-jaman ($p < 0,05$)

Perbandingan Pasangan	Jumlah Sampel (n)	Statistik Uji (W)	p -value	Signifikansi
IMERG vs ERA5 Reanalysis	6.242	6.786.152,00	$1,0626 \times 10^{-15}$	Berbeda Nyata (p)
GSMaP vs ERA5 Reanalysis	7.630	10.985.498,00	$6,3944 \times 10^{-33}$	Berbeda Nyata (p)
IMERG vs AWS Lokal	4.543	2.115.823,00	$3,1727 \times 10^{-124}$	Berbeda Nyata (p)
GSMaP vs AWS Lokal	6.258	4.908.156,00	$2,6437 \times 10^{-124}$	Berbeda Nyata (p)
ERA5 Reanalysis vs AWS Lokal	6.031	6.253.957,00	$2,2488 \times 10^{-48}$	Berbeda Nyata (p)

5.2 Uji Mann-Whitney U (Musim Hujan vs Musim Kemarau)

Uji Mann-Whitney U membandingkan distribusi presipitasi antara Musim Hujan (November–April, $n = 7.224$ jam) dan Musim Kemarau (Mei–Oktober, $n = 5.160$ jam). Hasil pada Tabel 4 membuktikan seluruh dataset menangkap kontras musiman tropis secara sangat signifikan ($p \leq 7,13 \times 10^{-7}$).

Tabel 4: Hasil Uji Mann-Whitney U: Musim Hujan (Nov–Apr) vs Musim Kemarau (Mei–Okt)

Dataset Presipitasi	Sampel Musim Hujan	Sampel Kemarau	p -value	Perbedaan Musim
GPM IMERG	7.224	5.160	$7,2312 \times 10^{-137}$	Sangat Signifikan ($p < 0,05$)
GSMaP	7.224	5.160	$7,1302 \times 10^{-07}$	Sangat Signifikan ($p < 0,05$)
ERA5 Reanalisis	7.224	5.160	$1,0168 \times 10^{-24}$	Sangat Signifikan ($p < 0,05$)
AWS Lokal	7.224	5.160	$1,9617 \times 10^{-199}$	Sangat Signifikan ($p < 0,05$)

6. Dinamika Temporal Deret Waktu Suhu & Presipitasi (2025–2026)

Gambar 10 memperlihatkan dinamika temporal suhu harian dan akumulasi bulanan presipitasi selama periode penelitian.


7. Analisis Fitur Fisik Atmosferik ERA5 untuk Pre-Training AI

Dalam arsitektur pembelajaran mesin dan *Deep Learning* (seperti BiLSTM dan XGBoost), data ERA5 digunakan untuk tahap *Pre-Training* fitur meteorologi fisik. Evaluasi korelasi dilakukan pada 13 parameter fisik atmosferik:


- Parameter Termodinamika & Permukaan:** temperature, humidity, dewpoint, pressure, rainrate.
- Parameter Dinamika Angin & Radiasi:** era5_u_wind (u_{10}), era5_v_wind (v_{10}), era5_direct_rad, era5_sunshine.
- Parameter Konvektif & Kolom Total:** era5_cloud_cover, era5_cape (*Convective Available Potential Energy*), era5_tcwv (*Total Column Water Vapour*), era5_moisture_div (*Moisture Divergence*).

Gambar 11 mengungkap korelasi fisis yang sangat konsisten dengan prinsip meteorologi tropis:


- Total Column Water Vapour (era5_tcwv):** Memiliki korelasi positif tertinggi terhadap presipitasi ($r = +0,27$, $\rho = +0,30$ pada hujan GSMaP; $r = +0,29$, $\rho = +0,51$ pada hujan ERA5).
- Moisture Divergence (era5_moisture_div):** Memiliki korelasi negatif kuat ($r = -0,18$, $\rho = -0,20$ pada GSMaP; $r = -0,86$ pada ERA5). Nilai divergensi negatif merepresentasikan konvergensi massa uap air yang memicu pertumbuhan awan konvektif pembawa hujan.
- Cloud Cover (era5_cloud_cover):** Berkorelasi positif kuat terhadap presipitasi ($r = +0,17$, $\rho = +0,24$).
- Tekanan Udara (pressure):** Berkorelasi negatif ($r = -0,13$, $\rho = -0,15$), sesuai dengan kondisi depresi tekanan rendah saat terjadi badai konvektif.




(a) Tren Rata-Rata Suhu Harian (ERA5 vs AWS Lokal)



(b) Tren Akumulasi Curah Hujan Bulanan (GSMaP, IMERG, ERA5, AWS Lokal)

(c) Tren Curah Hujan Rata-Rata Bergerak 7-Hari (*7-Day Moving Average*)


Gambar 10: Analisis Deret Waktu Dinamika Suhu dan Presipitasi di Kebumen (2025–2026).




Gambar 11: Matriks Korelasi 13×13 Fitur Atmosferik ERA5: (Atas) Presipitasi Baseline ERA5, (Bawah) Presipitasi Diganti Target Citra Satelit JAXA GSMaP.

8. Klimatologi 21 Tahun (2005–2025) & Variabilitas Jangka Panjang

Untuk menempatkan evaluasi jangka pendek 2025–2026 dalam konteks variabilitas iklim jangka panjang, dilakukan analisis klimatologi 21 tahun (2005–2025 / 252 bulan) di Kebumen.




Gambar 12: Tren Rata-Rata Suhu Bulanan ERA5 Kebumen (2005–2025) dengan Garis Tren Linier (+0,021°C/tahun).




Gambar 13: Perbandingan Tren Akumulasi Curah Hujan Bulanan (2005–2025) untuk GPM IMERG, GSMaP, dan ERA5 Reanalisis.

Temuan utama analisis klimatologi 20 tahun meliputi:


1. **Tren Pemanasan Suhu:** Terdapat laju peningkatan suhu permukaan rata-rata sebesar +0,021°C/tahun (+0,42°C dalam 2 dekade).
2. **Pola Puncak Musiman:** Curah hujan maksimum terjadi pada periode Desember–Februari (> 350 mm/bulan), dengan bulan terkering pada Juli–Agustus (< 80 mm/bulan).
3. **Dispersi Variabilitas:** Diagram kotak (*boxplot*) pada Gambar 15 membuktikan variabilitas presipitasi terbesar terjadi pada bulan Januari dan November, dengan kehadiran nilai ekstrem (*outliers*) saat fase puncak La Niña kuat (seperti tahun 2010 dan 2022).




Gambar 14: Pola Musiman Rata-Rata Curah Hujan Bulanan (Klimatologi 2005–2025) Berdasarkan GPM IMERG, GSMaP, dan ERA5.



Gambar 15: Diagram Kotak (*Boxplot*) Variabilitas Curah Hujan Bulanan Jerukagung dan Sekitarnya (2005–2025).



(a) Indeks Anomali Presipitasi Bulanan GPM IMERG



(b) Perbandingan Subplots Anomali 3 Produk: IMERG, GSMaP, dan ERA5

Gambar 16: Indeks Anomali Presipitasi Bulanan (2005–2025): Area biru menunjukkan surplus hujan (*La Niña / Wet Anomaly*) dan area merah menunjukkan defisit hujan (*El Niño / Dry Anomaly*).

9. Kesimpulan & Implikasi Pemodelan AI

Berdasarkan seluruh rangkaian evaluasi kuantitatif, statistik, dan fisis atmosferik, diperoleh kesimpulan sebagai berikut:

1. **Kinerja Produk Presipitasi:** JAXA GSMaP menunjukkan akurasi error terkecil ($MAE = 0,5252$ mm/jam, $RMSE = 1,4997$ mm/jam, $MBE = -0,0168$ mm/jam), sedangkan NASA GPM IMERG memiliki korelasi linier tertinggi ($r = 0,4105$).
2. **Validitas Reanalisis ERA5:** ERA5 terbukti sangat akurat dalam memodelkan suhu dan tekanan permukaan, serta menyediakan 13 fitur fisis kolom total (`tcwv`, `moisture_div`, `cape`, `cloud_cover`) yang memiliki relasi fisis konsisten terhadap kejadian presipitasi.
3. **Rekomendasi Pemodelan Deep Learning:** Strategi optimal untuk pemodelan prediksi presipitasi di Kebumen adalah:
 - **Tahap Pre-Training:** Memanfaatkan dataset jangka panjang ERA5 (2000–2026) dengan target presipitasi terkalibrasi JAXA GSMaP untuk membangun representasi fitur fisis atmosfer.
 - **Tahap Fine-Tuning:** Melakukan transfer learning dan adaptasi domain pada data observasi stasiun AWS IoT Jerukagung untuk mengeliminasi bias lokal.